

Dungeon AI

Deep Q-Learning em Haskell

Allan Messias · Denis Holanda · Enzo Farias · Robert
Richard · Victor Barbosa

6º ciclo de Ciência de Dados



Fatec
Baixada Santista
Ribeirão Preto

CPS
Centro
Paula Souza

 GOVERNO DO ESTADO
SÃO PAULO

O que é o Dungeon AI?



🧙 Um agente (mago) aprende a navegar por uma dungeon 5×5
💎 Objetivo: alcançar o tesouro desviando de armadilhas 🔥



🧠 Algoritmo: Deep Q-Learning (DQN)
💻 Linguagem: Haskell puro, sem frameworks de ML externos
🔧 Ferramentas: Antigravity, Git, GitHub Codespaces

O Ambiente – Grid World 5x5

Conceito: ambiente discreto onde o agente ocupa células em uma grade 5x5.

O agente começa na posição (0,0) e deve alcançar o objetivo em (4,4).

Tipos de Células:

- Livre — passagem normal
- 🔥 Armadilha — penalidade de -100 pontos
- 💎 Objetivo — recompensa de +100 pontos

Movimentos Possíveis:

↑ Cima | ↓ Baixo | ← Esquerda | → Direita

Sistema de Penalidades:

- Bater em parede: -2 pontos
- Cada passo dado: -1 ponto



Aprendizado por Reforço

1

Observar e Agir

O agente observa o estado atual (s) do ambiente, sua posição na dungeon. Com base nessa observação, escolhe uma ação (a): mover para cima, baixo, esquerda ou direita.

2

Recompensa e Transição

Após executar a ação, o agente recebe uma recompensa (r): +100 pelo tesouro , -100 por armadilhas , -1 por passo. Então transita para um novo estado (s').

3

Aprender e Repetir

O agente usa a experiência (s, a, r, s') para atualizar seu conhecimento. O ciclo se repete até dominar a navegação. "Aprender por tentativa e erro, maximizando recompensas."

Q-Learning – A Base Matemática

 Definição: $Q(s, a)$ é o valor esperado para ação "a" no estado "s"

 Na versão tabular, armazenado em matriz Q-Table

 Atualização pela Equação de Bellman:

$$Q^*(s, a) = r + \gamma \cdot \max_{a'} Q^*(s', a')$$

 $\gamma = 0,99$ — desconto para recompensas futuras

 Limitação: Q-Table não escala para estados grandes, por isso usamos redes neurais!

De Q-Table para Rede Neural

Q-Learning Tabular



Representação: Tabela



Escalabilidade: Limitada



Generalização: Nenhuma

✓ Complexidade: Simples

Deep Q-Learning (DQN)



Representação: Rede Neural



Escalabilidade: Alta

✓ Generalização: Entre estados similares



Complexidade: Requer

backpropagation

"A rede neural substitui a tabela,
permitindo generalização"

Como a IA Aprende?



Rede Neural Feedforward: Entrada com vetor de estado (12 features: posição do agente, armadilhas, objetivo). Camada oculta com 64 neurônios e ativação ReLU. Saída: 4 Q-values correspondentes às ações possíveis. Implementação do zero: forward pass, backpropagation e gradient descent.



Experience Replay Buffer: Armazena tuplas (s, a, r, s', done) de experiências passadas. Amostra mini-batches aleatórios de 32 experiências para treino. Quebra a correlação temporal entre amostras, garantindo aprendizado mais estável e eficiente.

O Dilema: Explorar ou Aproveitar?



Exploração (ϵ alto): Ações aleatórias para descoberta de novos caminhos. No início do treinamento, $\epsilon = 1,0$ significa 100% de ações aleatórias. O agente experimenta todas as possibilidades do ambiente sem preconceitos, construindo conhecimento base sobre a dungeon.



Exploração (ϵ baixo): Usa o conhecimento já aprendido para escolher a melhor ação conhecida. No final: $\epsilon \rightarrow 0,01$. Decaimento gradual: $\epsilon \times 0,995$ a cada episódio. "A IA começa explorando tudo e vai ficando mais inteligente com o tempo."



Limitações

1

O ambiente Grid World 5×5 é intencionalmente pequeno, e a rede neural, embora seja uma DQN, possui arquitetura mínima (entrada → 64 neurônios ReLU → 4 saídas). O foco está na correta implementação dos mecanismos do DQN (Experience Replay, ϵ -greedy e Equação de Bellman) e não na escala.


2

O agente é treinado e avaliado em um único cenário estático. Sem variação nos mapas durante o treinamento, a rede neural memoriza uma política ótima para aquele layout específico, sem capacidade de transferência direta para novos ambientes, o que é esperado e documentado como ponto de evolução futura do projeto.

3

O custo computacional escala com a complexidade do ambiente. Em um grid 5×5 com 4 ações possíveis, o treinamento converge em ~500 episódios. Grids maiores ampliam o espaço de estados, dificultam a exploração ϵ -greedy e aumentam o tempo necessário para que a rede neural generalize uma política eficiente.

Conceitos que Este Projeto Une



Inteligência Artificial

Agente autônomo, aprendizado por reforço, Deep Q-Learning (DQN)



Matemática Aplicada

Álgebra linear, cálculo, gradientes, Equação de Bellman



Programação Funcional

Haskell puro, imutabilidade, tipos algébricos, sem efeitos colaterais



Engenharia de Software

Arquitetura modular, testes automatizados, CI/CD com GitHub Actions.

Muito Obrigado!

A parte técnica (código, módulos e demonstração ao vivo)
será apresentada a seguir.